

Appunti di Interfacce Uomo-Macchina

G.C.

Università degli Studi dell'Insubria

Anno Accademico 2025-2026

Indice

1	Introduzione	4
1.1	Ciclo di Interazione	4
1.2	Evoluzione Storica delle Interfacce	4
1.3	Multimodalità vs Multimedialità	5
1.4	Applicazioni Reali	6
2	Segnali, Rumore e Filtraggio	7
2.1	Acquisizione dei Segnali Fisiologici	7
2.2	Teoria del Campionamento e Quantizzazione	8
2.3	Energia, Potenza e Signal to Noise Ratio (SNR)	9
2.4	Approfondimento sui Segnali Fisiologici (ECG e EDA)	11
2.4.1	Segnale ECG (Elettrocardiogramma)	11
2.4.2	Segnale EDA/GSR (Electrodermal Activity)	11
2.5	Filtraggio e Tecniche di Denoising	12
3	Machine Learning	14
3.1	Apprendimento e Tipi di Modelli	14
3.1.1	Tipologie di Apprendimento	14
3.1.2	Bias-Variance Tradeoff	14
3.2	Preparazione e Selezione dei Dati	15
3.2.1	La Maledizione della Dimensionalità (Curse of Dimensionality)	15
3.2.2	Feature Extraction e Feature Selection	15
3.2.3	Normalizzazione	16
3.3	Validazione del Modello	16
3.3.1	K-Fold e LOSO-CV	16
3.3.2	Data Leakage	17
3.3.3	Metriche di Valutazione	17
3.4	Algoritmi Principali di Classificazione	18
3.4.1	K-Nearest Neighbors (k-NN)	18
3.4.2	Decision Trees e Random Forest	18

3.4.3	Support Vector Machines (SVM)	18
3.4.4	Regressione Logistica (Logistic Regression)	19
4	Affective Computing	20
4.1	Definizione e Concetti	20
4.1.1	Modelli Categorici (Discreti) delle Emozioni	20
4.2	Analisi dell'Arousal e della Valenza (Circumplex Model di Russell)	20
4.3	Il Dataset DEAP e gli Standard di Riferimento	21
4.3.1	Dettagli dell'Esperimento DEAP	22
4.4	Limiti e Prospettive	23
5	Brain-Computer Interfaces (BCI)	24
5.1	Introduzione alle BCI	24
5.2	Tipologie di BCI	24
5.3	Componenti del Sistema BCI	24
5.4	Bande di Frequenza EEG	25
5.5	Sistema Internazionale 10-20	25
5.6	Paradigmi BCI	26
5.6.1	Paradigma P300 Speller	26
5.6.2	Paradigma Motor Imagery (Immaginazione Motoria)	27
5.7	Strumenti Software per la BCI	28
5.8	Applicazioni BCI e Dataset di Riferimento	28
6	Laboratorio ed Esercitazioni	29
6.1	Pipeline Analisi ECG	29
6.2	Pipeline Analisi EDA / GSR	30
6.3	Audio e Aliasing (Sottocampionamento)	31
6.4	Machine Learning Pratico (SVM e k-NN)	31
7	Eserciziario per lo Scritto	33
7.1	Esercizio Tipo 1: Campionamento e Aliasing	33
7.2	Esercizio Tipo 2: Quantizzazione, SNR e Bitrate	33
7.3	Esercizio Tipo 3: Filtraggio 1D (Array)	34
7.4	Esercizio Tipo 4: Valutazione Modelli (Matrice di Confusione)	35
7.5	Esercizio Tipo 5: Energia e Potenza di una Sinusoide	35
7.6	Esercizio Tipo 6: Filtraggio di Segnali Fisiologici	36
7.7	Esercizio Tipo 7: Domande Teoriche di Machine Learning	36
7.8	Esercizi Tipo 8: Campionamento e Quantizzazione (Multiple Choice & Calcoli)	37
7.8.1	Esercizi Numerici a risposta aperta	37

7.8.2	Esercizi a Risposta Multipla: Ragionamento	39
7.8.3	Esercizi Energia e Potenza su Sinusoidi	40
8	Casi di Studio: Dataset DEAP	41
8.1	Introduzione a DEAP	41
8.2	Formato di Valutazione (Self-Assessment)	41
8.3	Modality Fusion	42

Capitolo 1

Introduzione

In questo capitolo vengono introdotti i concetti base delle Interfacce Uomo-Macchina. Il corso esplora come l'uomo interagisce con i sistemi informatici e viceversa, comprese le componenti fisiche (segnali corporei) e gli algoritmi (Machine Learning) usati per dare un senso a questi dati.

1.1 Ciclo di Interazione

Di seguito uno schema generale dell'interazione Uomo-Macchina:




Figura 1.1: Schema del ciclo base di interazione tra uomo e macchina.

1.2 Evoluzione Storica delle Interfacce

L'interazione uomo-macchina ha subito profonde trasformazioni nel corso dei decenni. Possiamo riassumere questa evoluzione in 5 fasi principali:




Figura 1.2: Schema evolutivo delle Interfacce Uomo-Macchina.

- **Manuale (Batch):** Interazione indiretta tramite schede perforate e interruttori fisici.
- **Riga di Comando (CLI):** Interazione basata su testo, richiede conoscenza di sintassi e comandi specifici.
- **Interfacce Grafiche (GUI):** Introduzione del paradigma WIMP (Window, Icon, Menu, Pointer), rendendo l'uso accessibile alla massa.
- **Web e Mobile:** Interfacce touch, navigazione ipertestuale e proliferazione sugli smartphone.
- **Interfacce Multimodali e Intelligenti:** Interazioni naturali sfruttando voce, gesti e adattabilità del sistema (HCI moderna).

1.3 Multimodalità vs Multimedialità

È fondamentale distinguere tra concetti spesso confusi:

- **Multimedialità:** Si riferisce al sistema che comunica *all'utente* attraverso diversi tipi di media (testo, audio, video). Riguarda principalmente l'output.
- **Multimodalità:** Riguarda le modalità con cui l'utente fornisce input *alla macchina*. Un'interfaccia multimodale permette l'uso congiunto e sinergico di diversi canali, come:
 - **Voce e Parola** (es. Speech Recognition)
 - **Gesti e Postura**
 - **Eye-tracking** (tracciamento oculare)
 - **Segnali Fisiologici** (HR, EDA, EEG)

1.4 Applicazioni Reali

Le moderne HMI (Human-Machine Interfaces) trovano applicazione in contesti complessi e critici:

- **Realtà Virtuale (VR) e Aumentata (AR):** Utilizzate per simulazioni o supporto (es. torri di controllo aereo con interfacce aumentate per gestire alti flussi di dati visivi in modo efficiente).
- **Social Robots:** Robot impiegati come compagni per anziani o per supporto terapeutico, dotati di capacità di comprensione delle emozioni (Affective Computing).
- **Sistemi Assisistivi alla Guida (ADAS):** Rilevamento dello stato psicofisico del guidatore (stress, sonnolenza, fatica alla guida) misurando parametri corporei e comportamento oculare per prevenire incidenti.
- **Tecnologie Assistive:** Applicazioni cliniche per soggetti con gravi disabilità motorie (es. SLA), come esoscheletri robotici controllati da segnali muscolari/cerebrali, e sistemi di Brain-Computer Interface (BCI).

Capitolo 2

Segnali, Rumore e Filtraggio

2.1 Acquisizione dei Segnali Fisiologici

Il primo passo per interfacciare uomo e macchina è l'acquisizione di segnali dal corpo umano, tramite l'applicazione di elettrodi o sensori. Nel corso vengono trattati due tra i segnali più noti:

- **ECG (Elettrocardiogramma)**: Misura l'attività elettrica del cuore. Molto utile per rilevare l'Heart Rate (HR) e l'Heart Rate Variability (HRV), indicatori fondamentali dello stato di stress o del grado di attenzione dell'utente.
- **EDA/GSR (Electrodermal Activity / Galvanic Skin Response)**: Misura la conduttanza cutanea derivata dalla sudorazione. È un ottimo indicatore del livello di arousal (eccitazione fisiologica) di un individuo.




Figura 2.1: Catena di acquisizione dei segnali fisiologici bioelettrici.

In `Esercizio_ECG.m` e `Esercizio_GSR.m` sono state esplorate tecniche di lettura e plotting in ambienti come MATLAB, indispensabili per visualizzare e preparare i dati.

2.2 Teoria del Campionamento e Quantizzazione

Qualsiasi segnale fisiologico, essendo analogico e continuo, deve passare in un form factor digitale per poter essere elaborato dalla macchina.

- **Campionamento:** Determinato dal teorema di Nyquist-Shannon. Fissata una frequenza massima f_{max} del segnale di interesse, la frequenza di campionamento f_s deve essere:

$$f_s > 2f_{max} \quad (2.1)$$

Rispettare questa condizione permette di evitare il fenomeno dell'**aliasing**. Nel caso di sottocampionamento o decimazione (riduzione intenzionale di f_s), si verifica un "ripiegamento" delle frequenze superiori a $f_s/2$ (frequenza di Nyquist) sulle frequenze inferiori. Questo effetto crea una distorsione nota come "effetto fisarmonica" nello spettro, rendendo impossibile la ricostruzione fedele del segnale originale.




Figura 2.2: Fenomeno dell'aliasing: un segnale ad alta frequenza campionato troppo lentamente viene confuso con una bassa frequenza.

- **Quantizzazione:** Consiste nella mappatura di valori continui di ampiezza in un insieme finito di L livelli discreti, definiti dal numero di bit b :

$$L = 2^b \quad (2.2)$$

La distanza tra due livelli consecutivi, ovvero la **risoluzione (step d'intervallo)**, indicata con Δ , è data formalmente da:

$$\Delta = \frac{x_{max} - x_{min}}{L} \quad (2.3)$$

Nota: nella pratica e in alcuni esercizi, per mappare esattamente i valori limite tra 0 e $L - 1$, è frequente calcolare lo step dividendo per $L - 1$.

L'arrotondamento ai livelli produce un inevitabile **errore di quantizzazione**, assimilabile a un rumore additivo ed indipendente dal segnale in caso di risoluzione sufficiente. L'errore è confinato nell'intervallo $[-\Delta/2, \Delta/2]$.




Figura 2.3: Quantizzazione: approssimazione del segnale continuo a livelli discreti (gradini).

- **Dithering:** È una tecnica usata nella quantizzazione che consiste nell'aggiunta volontaria di rumore bianco (con una particolare distribuzione probabilistica, es. densità di probabilità PDF triangolare o rettangolare) prima del quantizzatore per *decorrelare* l'errore di quantizzazione dal segnale d'interesse, convertendo le distorsioni non-lineari e i toni spuri in un rumore di fondo uniforme, migliorando in media la fedeltà del segnale specialmente alle basse ampiezze.

2.3 Energia, Potenza e Signal to Noise Ratio (SNR)

L'acquisizione di segnali biologici è afflitta da instabilità e rumore, che può essere categorizzato in:

1. **Rumore Termico (o bianco):** Inerente ai componenti elettronici, presente su tutto lo spettro con potenza pressoché costante (es. rumore gaussiano).
2. **Artefatti da Movimento:** Causati dai micro-scivolamenti dell'elettrodo sulla pelle o movimenti muscolari. Si presenta spesso come variazioni di baseline a bassissima frequenza o picchi impulsivi (rumore spike).
3. **Interferenza di Rete (Powerline noise):** Rumore a 50 Hz (in Europa) o 60 Hz causato dall'accoppiamento con l'impianto elettrico.

Matematicamente, per caratterizzare un segnale valuto:

- **Energia:**

Continuo: $E = \int_{-\infty}^{+\infty} |x(t)|^2 dt$

Discreto: $E = \sum_{n=-\infty}^{+\infty} |x[n]|^2$

- **Potenza Media:**

Continuo: $P = \lim_{T \rightarrow \infty} \frac{1}{2T} \int_{-T}^T |x(t)|^2 dt$

Discreto: $P = \lim_{N \rightarrow \infty} \frac{1}{2N+1} \sum_{n=-N}^N |x[n]|^2$

Caso d'esame: Segnale Sinusoidale Dato un segnale sinusoidale $x(t) = A \cos(2\pi ft + \phi)$ esteso su tutto l'asse temporale ($-\infty < t < +\infty$):

- **Energia (E):** È sempre **Infinita** (∞), poiché l'integrale di una funzione periodica su tempo infinito diverge.
- **Potenza (P):** È **Finita** e vale sempre $P = \frac{A^2}{2}$.
- *Nota bene:* La potenza media di una senoide **non dipende dalla frequenza** o dalla fase. Se la frequenza raddoppia, la potenza rimane invariata!

Il **SNR (Signal-to-Noise Ratio)** è la metrica principale per definire la pulizia di un segnale rispetto ai disturbi acquisiti dai sensori o creati dai circuiti:

$$SNR_{dB} = 10 \log_{10} \left(\frac{P_{seg}}{P_{rum}} \right) \quad (2.4)$$

Maggiore è l'SNR, migliore è la qualità dell'informazione. Nel caso specifico del rumore introdotto dalla sola quantizzazione, possiamo calcolare empiricamente il Signal-to-Quantization-Noise Ratio (SQNR) in decibel in base al numero di bit b :

$$SQNR \approx 6.02 \cdot b + 1.76 \text{ [dB]} \quad (2.5)$$

2.4 Approfondimento sui Segnali Fisiologici (ECG e EDA)

2.4.1 Segnale ECG (Elettrocardiogramma)

L'ECG evidenzia il funzionamento cardiaco. È caratterizzato, nel singolo battito, dal **complesso QRS** (depolarizzazione dei ventricoli), che presenta il picco R primario. Lo studio si basa sull'**HRV (Heart Rate Variability)**, che è la variazione nel tempo tra un battito e il successivo. Gli intervalli R-R sono usati per estrarre metriche fondamentali:

- **SDNN**: Deviazione standard degli intervalli N-N (R-R normali), denota variabilità a lungo termine.
- **RMSSD**: Root mean square successive difference, che riflette l'influenza parasimpatica immediata.

Spesso il segnale ECG presenta una deriva della linea di base (baseline wander) attribuibile alla respirazione e ai movimenti. Viene facilmente compensata con tecniche di regressione polinomiale o operando una funzione *detrend*.

2.4.2 Segnale EDA/GSR (Electrodermal Activity)

I segnali galvanici (GSR) variano con la sudorazione del palmo o delle dita. Questo segnale è composto dalla somma di due parti distinte da separare algebricamente:

- **Componente Tonica (SCL - Skin Conductance Level)**: Molto lenta, misurabile in periodi prolungati; indica uno stato generale (es. stress a lungo termine, allerta prolungata). Subisce fenomeni di drift nel tempo. Si estrae per esempio con un filtro passa-basso con taglio a ~ 0.05 Hz.

- **Componente Fasica (SCR - Skin Conductance Response):** Estremamente veloce, sovrapposta alla tonica; rappresenta le reazioni istantanee a stimoli emotivi specifici (es. paura, sorpresa). Presenta dei *picchi* tipici. Isolata rimuovendo la tonica, si usa solitamente un passa-basso a $\sim 1-2$ Hz.

2.5 Filtraggio e Tecniche di Denoising

Per pulire i segnali vengono adoperati vari filtri di elaborazione del segnale digitale:

Filtri Passa-Basso, Passa-Alto e Passa-Banda: Rimuovono componenti di frequenza specifiche. Tra i filtri standard vi è il **Filtro Butterworth**, che è massimamente piatto in banda passante. La pendenza (roll-off) del filtro è direttamente legata all'*ordine* del filtro. Attenzione: aumentare troppo l'ordine porta a instabilità e fenomeni di *ringing* (oscillazioni spurie o sovraelongazioni pre e post-filtro).

Frequenza Lineari vs Non-Lineari (Media vs Mediano):

- Il **Filtro della Media (Moving Average)** è un filtro lineare. L'equazione per una finestra di dimensione W (dispari, con $k = (W - 1)/2$) è:

$$y[n] = \frac{1}{W} \sum_{i=-k}^k x[n-i] \quad (2.6)$$

È ottimo per attenuare rumore bianco (gaussiano). Tuttavia, in presenza di un rumore impulsivo (outlier), la media ne risente e finisce per "spalmare" l'errore sui campioni vicini, addolcendo eccessivamente i fronti di salita (bordi netti).

- Il **Filtro Mediano** è un operatore di rango **non lineare**. L'equazione è:

$$y[n] = \text{mediano}(\{x[n-k], \dots, x[n], \dots, x[n+k]\}) \quad (2.7)$$

Eccellente e robusto per scartare rumori impulsivi (spike o salt & pepper): un singolo valore outlier viene completamente ignorato dal calcolo del mediano; in più, esso riesce a preservare in modo intatto i fronti di salita rapidi del segnale, risultando essenziale in morfologie a gradino o picchi importanti.

Caratteristica	Filtro Media (Moving Avg)	Filtro Mediano
Tipo	Lineare	Non Lineare
Rumore Gaussiano	Attenua bene	Distorce leggermente
Rumore Impulsivo (Spike)	Spalma l'errore (inefficace)	Elimina lo spike (ottimo)
Bordi netti / Gradini	Addolcisce (sfoca)	Preserva intatti

Tabella 2.1: Tabella comparativa: Filtro Media vs Filtro Mediano.

Scelta dei Filtri nella pratica clinica (ECG/EDA) Nelle interfacce fisiologiche, ogni rumore ha un filtro specifico ideale:

Problema / Artefatto	Causa	Soluzione
Deriva linea di base (Drift)	Respiro, sudorazione lenta (SCL), movimento cavi.	Filtro Passa-Alto (es. taglio a 0.5 Hz) o detrend .
Rumore di Rete (Ronzio)	Cavi elettrici nella stanza, interferenza.	Filtro Notch (Arresta-banda) centrato a 50 Hz.
Rumore Muscolare (EMG)	Contrazioni muscolari ad alta frequenza sovrapposte.	Filtro Passa-Basso (es. taglio a 25 – 40 Hz).
Spike improvvisi	Urto dell'elettrodo, disconnessione rapida.	Filtro Mediano (scarta l'outlier senza spalmarlo).
Effetto "Ringing"	Ordine del filtro (es. Butterworth) troppo elevato su transizioni rapide.	Abbassare l'ordine del filtro.

Tabella 2.2: Guida pratica alla scelta dei filtri per segnali bioelettrici.

Capitolo 3

Machine Learning

Il **Machine Learning** (ML) ricopre un ruolo fondamentale nelle interfacce uomo-macchina, e in particolare nelle *Brain-Computer Interfaces* (BCI) o nei sistemi di *Affective Computing*. L'obiettivo primario è elaborare un insieme di dati fisiologici per classificarli in stati ben definiti (es. stress, rilassamento, comandi motori).

3.1 Apprendimento e Tipi di Modelli

Nel contesto delle interfacce biometriche, si predilige prevalentemente l'approccio **Supervisionato**.

3.1.1 Tipologie di Apprendimento

- **Apprendimento Supervisionato:** Il modello viene addestrato su un dataset fornito di *labels* (etichette) che fungono da parametro di verità (es. input X = segnale EEG, output Y = stato di "concentrazione").
- **Apprendimento Non Supervisionato:** I dati non hanno etichette. Il modello cerca di identificare cluster o anomalie strutturali al loro interno (e.g., K-Means).

3.1.2 Bias-Variance Tradeoff

Il successo di un modello predittivo dipende dall'equilibrio tra due fonti di errore:

- **Bias (Errore di Approssimazione):** Il modello è troppo semplice per catturare i pattern dei dati (es. usare una retta per dati quadratici).

Causa **Underfitting** (scarse prestazioni sia in addestramento che in test).

- **Varianza (Sensibilità al Rumore):** Il modello è troppo complesso e impara a memoria i dati di addestramento, incluso il rumore. Causa **Overfitting** (ottime prestazioni in addestramento, pessime sui nuovi dati).

L'**obiettivo** è trovare il *Tradeoff* (compromesso) ideale che minimizzi entrambi gli errori, garantendo la miglior **generalizzazione** su dati mai visti.

3.2 Preparazione e Selezione dei Dati

3.2.1 La Maledizione della Dimensionalità (Curse of Dimensionality)

Avere più *feature* (variabili) non significa sempre avere risultati migliori. Oltre un certo limite si verifica il **Fenomeno di Hughes**:

- **Dati sparsi:** Aumentando le dimensioni, il volume dello spazio dei dati cresce esponenzialmente e i campioni diventano troppo isolati tra loro.
- **Distanze inefficaci:** In spazi ad alta dimensionalità, la distanza tra il punto "più vicino" e quello "più lontano" tende ad annullarsi, rendendo inefficaci algoritmi basati sulla distanza euclidea (es. k-NN).

3.2.2 Feature Extraction e Feature Selection

Per ridurre l'alta dimensionalità si usano due approcci:

- **Feature Extraction (es. PCA):** Trasforma le variabili originali creandone di nuove (in numero minore) che riassumono la maggior quantità di informazione (varianza) possibile.
- **Feature Selection:** Seleziona solo un sottoinsieme delle variabili originali più utili. Ad esempio, calcolando la **Correlazione di Pearson**, si eliminano le feature troppo simili tra loro (valori vicini a 1 o -1), riducendo la ridondanza.

3.2.3 Normalizzazione

Molto importante, specialmente per i classificatori che si basano sulle distanze spaziali, poiché evita che metriche di grandezza assoluta maggiore monopolizzino lo spazio mascherando le metriche piccole:

- **Min-Max Scaling:** Conduce forzatamente tutti i valori in un range prestabilito, normamente $[0, 1]$.
- **Standardization (Z-Score):** Impone che le proiezioni campionarie abbiano una media statistica di "zero" e una varianza "unitaria", riadattando il *range* secondo la deviazione standard del set: $z = \frac{x - \mu}{\sigma}$.

Attenzione: Procedura corretta di Normalizzazione

La normalizzazione NON deve mai essere applicata all'intero dataset prima della divisione in Training e Test. La pipeline corretta prevede:

1. **Split:** Dividere i dati in Train e Test.
2. **Fit:** Calcolare i parametri (es. Min e Max, o Media e Varianza) *esclusivamente* sul Training set.
3. **Transform:** Applicare la formula di normalizzazione al Training set e, utilizzando gli stessi identici parametri appena calcolati, normalizzare anche il Test set.

Questo impedisce al modello di "sbirciare" (Data Leakage) la distribuzione dei dati futuri.

3.3 Validazione del Modello

Nel panorama dei segnali fisiologici, in continua variazione soggettiva nel tempo, il classico random-split in "Train" e "Test" (*Holdout Method*) può portare a conclusioni gravemente ingannevoli.

3.3.1 K-Fold e LOSO-CV

- **K-Fold Cross Validation:** Il dataset è diviso in K parti uguali. A turno, una parte fa da Test e le rimanenti $K - 1$ da Training. Utile per stabilizzare i risultati.

- **LOSO-CV (Leave-One-Subject-Out):** Fondamentale nelle interfacce uomo-macchina. Se ci sono N soggetti, il modello si addestra su $N - 1$ individui e si testa sull'individuo escluso. Si ripete per tutti. Serve a verificare se il sistema è **Subject-independent**, ovvero capace di funzionare su un **nuovo utente** mai visto prima.

3.3.2 Data Leakage

Il **Data Leakage** (Fuga di dati) avviene quando informazioni del set di *Test* finiscono accidentalmente nel set di *Training*. Questo porta il modello a sembrare perfetto in fase di validazione, ma a fare **Overfitting** e fallire miseramente su dati reali.

Nei segnali fisiologici, i due casi più comuni di Data Leakage sono:

- **Normalizzazione pre-split:** Calcolare il Min/Max o la Media globale sull'intero dataset *prima* di dividerlo. Così facendo, le metriche del Test set influenzano la scalatura dei dati di addestramento.
- **Finestre temporali sovrapposte (Overlapping):** Estrarre finestre da un segnale continuo (es. EEG) con elevato overlap e fare uno split casuale (random holdout). È altissima la probabilità che finestre quasi identiche finiscano in parte nel Train e in parte nel Test.

3.3.3 Metriche di Valutazione

1. **Accuracy (Accuratezza):** Percentuale di previsioni corrette sul totale. È fuorviante se il dataset è **fortemente sbilanciato** (es. 90% classe A, 10% classe B).

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \quad (3.1)$$

2. **Precision (Precisione):** Quanti, tra quelli classificati come positivi, lo sono *effettivamente*?

$$Precision = \frac{TP}{TP + FP} \quad (3.2)$$

3. **Recall (Sensibilità o TPR):** Quanti positivi reali sono stati individuati correttamente? Minimizza i Falsi Negativi, fondamentale in ambito medico.

$$Recall = \frac{TP}{TP + FN} \quad (3.3)$$

4. **F1-Score:** Media armonica tra Precision e Recall. È la metrica ideale per dataset sbilanciati.

$$F1 = 2 \cdot \frac{Precision \cdot Recall}{Precision + Recall} \quad (3.4)$$

3.4 Algoritmi Principali di Classificazione

3.4.1 K-Nearest Neighbors (k-NN)

Algoritmo *non parametrico* e *lazy learner*: non ha una vera fase di addestramento. A runtime, classifica un nuovo dato assegnandogli la classe maggioritaria tra i suoi " K vicini" più prossimi nello spazio delle feature.

- **Scelta di K :** Un K troppo piccolo ($K = 1$) modella eccessivamente il rumore (**Overfitting**). Aumentando K , i confini decisionali diventano più lisci (**Generalizzazione**). Un K troppo grande porta a **Underfitting**.

3.4.2 Decision Trees e Random Forest

Decision Trees (Alberi Decisionali): Classifica i dati creando regole binarie a cascata sulle *feature*. Ad ogni snodo, sceglie la regola che minimizza l'*Impurità* dei dati, calcolata ad esempio con:

$$Indice\ di\ Gini = 1 - \sum_i (p_i)^2 \quad (3.5)$$

Il limite principale dell'Albero singolo è la forte tendenza all'**Overfitting**.

Random Forest: Usa l'**Ensemble Learning** (*Bagging*) per risolvere l'overfitting dei Decision Trees. Addestra numerosi alberi decisionali su sottoinsiemi casuali di dati e di feature. La classificazione finale avviene per **Majority Voting** (maggioranza), garantendo stabilità e alta precisione.

3.4.3 Support Vector Machines (SVM)

Cerca l'**Iperpiano** (un asse o piano di separazione) che divida in modo ottimale due classi, massimizzando il **Margine** di distanza tra esse. I campioni più vicini all'iperpiano sono detti *Support Vectors*.

$$w \cdot x + b = 0 \quad (\text{Equazione dell'Iperpiano lineare, margine } \frac{2}{||w||}) \quad (3.6)$$

- **Soft Margin (Parametro C):** Per dataset non perfettamente separabili, si ammette un certo margine di errore. Il parametro C regola questo compromesso: un C alto penalizza duramente gli errori (*Overfitting*), un C basso tollera qualche errore per favorire un margine più ampio (*Generalizzazione*).
- **Kernel Trick:** Permette di applicare la SVM a problemi **non lineari**. Mappa i dati in uno spazio a dimensioni superiori tramite funzioni matematiche (es. Kernel Lineare, Polinomiale, RBF) dove i dati diventano separabili linearmente, senza pesare eccessivamente sui calcoli.




Figura 3.1: Rappresentazione essenziale concettuale di una SVM lineare bi-dimensionale. Sono evidenziati tangibilmente i vettori di supporto e le equazioni degli iperpiani corrispondenti al margine esatto **massimo**.

3.4.4 Regressione Logistica (Logistic Regression)

Nasce per la regressione ma è un ottimo classificatore binario (estendibile al multi-classe). Passa l'equazione della retta attraverso una **Funzione Sigmoide**:

$$\sigma(z) = \frac{1}{1 + e^{-z}} \quad (3.7)$$

Questo "schiaccia" il risultato in un intervallo $[0, 1]$, trasformandolo in una **probabilità**. Invece di usare l'errore quadratico medio, utilizza come funzione di costo la **Log-Loss (Cross-Entropy Loss)**. Essendo una funzione matematica convessa, garantisce che l'algoritmo di *Discesa del Gradiente* trovi sempre il minimo globale, evitando di bloccarsi nei minimi locali.

Capitolo 4

Affective Computing

4.1 Definizione e Concetti

L'Affective Computing è il campo di studio che si occupa dello sviluppo di sistemi in grado di riconoscere, interpretare, processare e simulare le emozioni umane.

4.1.1 Modelli Categorici (Discreti) delle Emozioni

Prima di passare a modelli continui, la teoria psicologica ha storicamente definito le emozioni tramite categorie discrete universali:

- **Modello di Ekman:** Identifica **6 emozioni di base** universali transculturali: Gioia, Tristezza, Rabbia, Paura, Disgusto e Sorpresa, rintracciabili tramite micro-espressioni facciali.
- **Ruota di Plutchik:** Estende il modello a **8 emozioni primarie** organizzate in coppie di opposti (Es. Gioia/Tristezza, Fiducia/Disgusto, Paura/Rabbia, Sorpresa/Anticipazione). Le emozioni complesse derivano dalla fusione di queste primarie.

4.2 Analisi dell'Arousal e della Valenza (Circumplex Model di Russell)

Per dare una classificazione continua alle emozioni, piuttosto che appoggiarsi a categorie base (e.g. gioia, rabbia, tristezza, paura, disgusto, sorpresa di Ekman), ci si basa storicamente sul modello circonflesso introdotto da Russell nel 1980. Esso mappa le sensazioni umane su uno spazio bidimensionale continuo:

- **Asse Y - Arousal (Attivazione):** Grado dell'energia associata all'emozione (Es. Basso: dormiente / Alto: frenetico, allertato).
- **Asse X - Valence (Valenza):** Disposizione qualitativa o umore (Es. Basso: spiacevole, negativo / Alto: piacevole, positivo).




Figura 4.1: Il Modello Circonflesso delle Emozioni (Russell, 1980).

Ad esempio, alta valenza e alto arousal corrispondono all'eccitazione/felicità (Happy), mentre bassa valenza e alto arousal ricadono sotto stress emotivi come ansia o rabbia (Angry).

4.3 Il Dataset DEAP e gli Standard di Riferimento

Per fornire benchmark validi sulle macchine di classificazione emozionale (spesso affrontate in ambito *Affective BCI*) è stato standardizzato il **DEAP Dataset** (Database for Emotion Analysis using Physiological Signals).

4.3.1 Dettagli dell'Esperimento DEAP

L'esperimento DEAP è una pietra miliare configurata con estremo rigore:

- **Partecipanti e Stimoli:** 32 partecipanti hanno visionato 40 video musicali della durata di 1 minuto ciascuno, precedentemente selezionati tramite i tag affettivi del sito *Last.fm* per coprire uniformemente i vari quadranti emotivi.
- **Acquisizione dati:** Registrazione multimodale che include EEG (32 canali), segnali periferici associati al sistema nervoso autonomo (GSR, temperatura corporea, frequenza respiratoria, ECG, fotopletismogramma) e per 22 partecipanti anche le espressioni facciali su video.
- **Ground Truth e SAM:** Come si etichettano le emozioni intime in un dataset? Ai candidati veniva chiesto di compilare una scala **SAM (Self-Assessment Manikin)** per fornire l'autovalutazione di *Arousal*, *Valenza*, *Dominanza* e *Liking*. In questo ambito è cruciale la differenza tra **emozioni espresse** (il soggetto "mostra" un'emozione, magari simulata) ed **emozioni suscitate** o *felt emotions* (ciò che il soggetto "sente" realmente in risposta allo stimolo musicale), di cui il SAM cattura la *ground truth*.
- **Modality Fusion:** La vera innovazione dell'approccio risiede nella fusione decisionale (*decision/modality fusion*): i modelli di machine learning raggiungono le performance migliori non usando il singolo biosegnale, ma incrociando i dati cerebrali e periferici con la **MCA (Multimedia Content Analysis)**, ovvero le caratteristiche estratte automaticamente dal contenuto dei video musicali mostrati come stimolo (ritmo, colori, ecc.). Il video del volto dei partecipanti, pur essendo stato registrato per 22 soggetti, non è stato utilizzato nei task di classificazione di questo studio.

Questa fusione di dati multicanale biologici ha reso accessibile l'allenamento di task algoritmici predittivi sul reale stato emozionale del soggetto al computer, con importanti ricadute in settori quali salute mentale pre-clinica (e.g. detection ansia), User Experience, ed intrattenimento (ad esempio dinamiche di giochi modificate dalle reazioni biologiche misurate del giocatore).

4.4 Limiti e Prospettive

A differenza del tracking del mouse o della frequenza di click usati nei convenzionali tool di software tracking, la biologia non mente: per il soggetto risulta arduo alterarne le micro-reazioni (*lie-detector principle*). Questo porta ad un incredibile margine di veridicità del dato acquisito ad una velocità real-time, ma contemporaneamente il suo grosso limite è la scalabilità: ogni candidato porta variazioni intra-soggetto per cui i modelli non riescono sempre a "generalizzare" un approccio universale ma necessitano della fase di calibrazione *in-situ*.

Capitolo 5

Brain-Computer Interfaces (BCI)

5.1 Introduzione alle BCI

Le interfacce Cervello-Computer stabiliscono un percorso di comunicazione diretta tra un cervello e un dispositivo esterno. Spesso dirette ad assistere, aumentare o riparare le funzioni cognitive o sensori-motorie umane.

5.2 Tipologie di BCI

Vi sono due grandi categorie per i sistemi BCI in base a come il cervello viene monitorato:

- **Invasive:** Vengono impiantati elettrodi direttamente nel cervello. Hanno un'alta qualità di segnale (SNR molto alto) ma presentano rischi significativi per la salute del paziente e cicatrici nel tessuto cerebrale che nel tempo riducono l'efficacia del segnale.
- **Non-Invasive:** Utilizzano dispositivi posti all'esterno del cranio, come per l'elettroencefalografia (EEG). Pur avendo una risoluzione spaziale inferiore e maggiore suscettibilità al rumore (ad esempio rumori muscolari o movimenti agli occhi), offrono il grande vantaggio di essere sicure per l'utente, non richiedendo procedure chirurgiche.

5.3 Componenti del Sistema BCI

Un sistema tipico è composto da varie fasi di elaborazione:

1. **Acquisizione del Segnale:** Tramite hardware dedicato e sensori (ad esempio, cuffie EEG).
2. **Pre-processing ed Estrazione delle Features:** Rimozione del rumore (filtraggio, e.g. notch filter per rimuovere frequenza di rete) ed isolamento delle caratteristiche del segnale utili per decodificare l'intento.
3. **Classificazione / Traslazione (Machine Learning):** L'algoritmo traduce le feature estratte in un comando di controllo specifico usando modelli (come SVM o reti neurali).
4. **Output del Dispositivo e Feedback:** Il comando viene eseguito (muovere un cursore, un braccio robotico, fare lo spelling di una parola) e all'utente viene dato un feedback visivo o tattile relativo alla sua azione, in modo tale che il suo cervello possa imparare ad adattare il segnale.




Figura 5.1: Ciclo *Closed-Loop* del sistema Brain-Computer Interface.

5.4 Bande di Frequenza EEG

Quando si analizzano segnali cerebrali non-invasivi, i tracciati EEG vengono usualmente divisi in bande di frequenza, ciascuna associata a determinati stati mentali:

5.5 Sistema Internazionale 10-20

Per standardizzare il posizionamento degli elettrodi sullo scalpo si usa il **Sistema 10-20**, basato su percentuali (10% o 20%) della distanza totale tra

Banda	Frequenza	Stato Cognitivo / Attività
Delta (δ)	< 4 Hz	Sonno profondo negli adulti, patologie in veglia.
Theta (θ)	4 – 7 Hz	Sonnolenza, meditazione profonda, sonno leggero.
Alpha (α)	8 – 12 Hz	Veglia rilassata (occhi chiusi). Dominante nei lobi occipitali.
Ritmo Mu (μ)	8 – 12 Hz	Sovrapposto all'Alpha ma sulla corteccia motoria. Si desincronizza durante il movimento reale o immaginato.
Beta (β)	12 – 30 Hz	Veglia attiva, forte concentrazione, calcolo mentale.
Gamma (γ)	30 – 80 Hz	Elaborazione multisensoriale complessa, consolidamento memorie (spesso disturbata da artefatti muscolari).

Tabella 5.1: Tabella riassuntiva delle principali bande di frequenza EEG.

punti anatomici chiave (Nasion, Inion, e preauricolari). Le lettere indicano il lobo sottostante (**F** = Frontale, **C** = Centrale, **T** = Temporale, **P** = Parietale, **O** = Occipitale), mentre i numeri indicano l'emisfero:

- **Numeri Dispari (1, 3, 5...):** Emisfero Sinistro.
- **Numeri Pari (2, 4, 6...):** Emisfero Destro.
- **Z (Zero):** Linea Mediana (Midline, es. Fz, Cz, Pz).

5.6 Paradigmi BCI

5.6.1 Paradigma P300 Speller

È uno dei sistemi BCI più famosi, permette a un utente di scrivere parole. Sfrutta il potenziale **P300**, una deflessione positiva dell'onda EEG (Event-Related Potential o **ERP**) che compare circa **300 ms** dopo uno stimolo atteso e raro (effetto **Oddball**).

- **Funzionamento:** L'utente guarda uno schermo con una matrice 6×6 di lettere. Le righe e le colonne lampeggiano in modo casuale. Quando




Figura 5.2: Diagramma a stati semplificato del funzionamento del P300 Speller.

lampeggia la riga/colonna contenente la lettera desiderata, il cervello emette l'ERP P300. Intersecando riga e colonna la macchina deduce il carattere.

- **Averaging:** Poiché il P300 ha un'ampiezza di pochi μV , sommerso dal rumore di fondo (basso SNR), si richiede l'**Averaging** (media sincrona) su svariati flash. Mediando N ripetizioni (trial), il SNR migliora di un fattore proporzionale a $\sqrt{N}$.
- **Attenzione:** Esiste l'attenzione *Overt* (l'utente fissa direttamente la lettera spostando gli occhi) ed *Covert* (l'utente tiene gli occhi fissi al centro, ma concentra l'attenzione mentale sulla lettera). Il sistema P300 con *Overt* attention è infinitamente più performante, dipendendo più da variazioni visive corticali.

5.6.2 Paradigma Motor Imagery (Immaginazione Motoria)

Nei pazienti completamente paralizzati (LIS - Locked-In Syndrome) è impossibile usare sistemi visivi complessi. La BCI **Motor Imagery** rileva le variazioni del **Ritmo μ** (Mu) causate dalla sola *immaginazione* di compiere un gesto (es. muovere la mano destra o i piedi). L'immaginazione attiva le stesse mappe neurali dell'esecuzione fisica causando una Desincronizzazione (ERD) sul lobo controlaterale.

5.7 Strumenti Software per la BCI

L'elaborazione dei dati EEG richiede suite massive. Durante il corso sono stati menzionati:

- **EEGLAB:** Un toolbox per MATLAB potente per processare il segnale offline. Utilizza algoritmi avanzati come l'**ICA** (Independent Component Analysis) essenziale per separare in modo cieco il segnale EEG reale dagli artefatti oculari o muscolari, rimuovendo la "componente" spuria del battito di ciglia.
- **OpenViBE:** Un software grafico intuitivo pensato per la creazione rapida, l'acquisizione e il routing del segnale in tempo reale per applicazioni BCI live e Neurofeedback.

5.8 Applicazioni BCI e Dataset di Riferimento

Tra i dataset più noti per lo sviluppo ed allenamento di questi modelli spiccano dataset come **DEAP** nel quale vi è una proficua unione tra segnali biologici legati alle emozioni (Affective Computing) e segnali EEG, permettendo approcci ibridi (Affective BCI).

Capitolo 6

Laboratorio ed Esercitazioni

In questo capitolo vengono raccolti gli snippet di codice essenziali (in ambiente MATLAB) relativi alle esercitazioni del corso. Questi esempi formano la base pratica per lo sviluppo del progetto d'esame.

6.1 Pipeline Analisi ECG

L'elaborazione dell'elettrocardiogramma richiede la pulizia del segnale prima dell'individuazione dei picchi R, al fine di estrarre l'Heart Rate (HR) e gli intervalli R-R.

- **Pre-processing:** Utilizzo di `detrend` per rimuovere la *wandering baseline* (deriva a bassa frequenza causata dalla respirazione o movimenti). Successivamente, si applica un filtro Passa-Banda (es. Butterworth tra 0.5 Hz e 25 Hz) per rimuovere rumori ad alta frequenza come i tremori muscolari e l'interferenza di rete (50 Hz).
- **Feature Extraction:** Uso di `islocalmax` (o `findpeaks`) con un parametro `MinProminence` adeguato per identificare esclusivamente i picchi R (che sono i più alti), ignorando le onde P e T. Dai picchi trovati, si calcola la differenza temporale tra essi (intervalli R-R) e si ricava l'HR in battiti al minuto (bpm).

```
% 1. Rimozione della deriva di linea di base
ecg_detrend = detrend(ecg_raw, 'linear');

% 2. Filtraggio passa-banda
% (es. per rimuovere rumore muscolare e rete)
[b, a] = butter(2, [0.5 25]/(fs/2), 'bandpass');
```

```

% filtfilt evita sfasamenti temporali
ecg_filt = filtfilt(b, a, ecg_detrend);

% 3. Individuazione dei picchi R (complesso QRS)
% MinProminence e' essenziale per ignorare
% picchi spuri come le onde T o P
[peaks, locs] = islocalmax(ecg_filt, 'MinProminence', 0.5);

% 4. Calcolo degli intervalli R-R e HR
rr_intervals_sec = diff(locs) / fs;
hr_bpm = 60 ./ rr_intervals_sec;

figure; hold on;
plot(t, ecg_filt);
plot(t(locs), ecg_filt(locs), 'r*', 'MarkerSize', 8);
title('ECG-con-Picchi-R');

```

6.2 Pipeline Analisi EDA / GSR

Per l'attività elettrodermica si rende necessaria la separazione della componente tonica (SCL) da quella fasica (SCR) per poter valutare lo stress o il carico cognitivo.

- **Pre-processing:** Applicazione di un filtro Passa-Basso con frequenza di taglio molto bassa (es. 0.05 Hz) per estrarre la Skin Conductance Level (SCL, l'andamento lento e generalizzato). Sottraendo la SCL al segnale originale ($\text{Raw} - \text{SCL}$) si ottiene la Skin Conductance Response (SCR, i picchi rapidi associati agli eventi).
- **Feature Extraction:** Uso di `findpeaks` o `islocalmax` sulla SCR per contare il numero di picchi emotivi (eventi). L'ampiezza o l'area sotto questi picchi è direttamente proporzionale all'arousal (attivazione emotiva) dell'utente in risposta a uno stimolo.

```

% 1. Estrazione Componente Tonica (SCL)
% - Filtro Passa-Basso molto stretto
fc_scl = 0.05; % Hz
[b_ton, a_ton] = butter(2, fc_scl/(fs/2), 'low');
GSR_tonica = filtfilt(b_ton, a_ton, gsr_raw);

```

```

% 2. Estrazione Componente Fasica (SCR)
GSR_fasica = gsr_raw - GSR_tonica; % Sottrazione

% In alternativa, si puo' filtrare direttamente
% in passa-banda il segnale grezzo per isolare la fasica
fc_scr = [0.05 1]; % Hz (es. da 0.05 a 1 Hz)
[b_fas, a_fas] = butter(2, fc_scr/(fs/2), 'bandpass');
GSR_fasica_filt = filtfilt(b_fas, a_fas, gsr_raw);

% 3. Individuazione dei picchi emotivi (Eventi fasici)
[peaks_eda, locs_eda] = islocalmax(GSR_fasica,
'MinProminence', 0.01);
num_eventi = sum(peaks_eda); % Conteggio eventi di stress

```

6.3 Audio e Aliasing (Sottocampionamento)

Per testare gli effetti del teorema di Nyquist-Shannon è utile procedere con la decimazione (downsampling) di un segnale audio pre-registrato.

```

% Caricamento audio originale
% (fs = 44100 Hz solitamente)
[y, fs_orig] = audioread('brano.wav');

% Fattore di sottocampionamento
M = 4;
y_down = y(1:M:end); % Salto M-1 campioni
fs_nuova = fs_orig / M; % Nuova frequenza di camp.

% Riproduzione: si notera' l'aliasing se
% fs_nuova < 2*f_max_segnale
sound(y_down, fs_nuova);

```

6.4 Machine Learning Pratico (SVM e k-NN)

Nell'ecosistema MATLAB l'applicazione di algoritmi di Machine Learning (come SVM e k-NN) è agevolata da funzioni built-in. È essenziale impostare la **standardizzazione dei dati** ('Standardize', true) per assicurarsi che le feature abbiano media e deviazione standard comparabili. Inoltre, l'utilizzo della **K-Fold Cross Validation** tramite `crossval` è fondamentale per

avere stime di accuratezza più affidabili e generalizzabili rispetto al semplice holdout (train-test split), specialmente per dataset di dimensioni contenute.

```
% Addestramento di una Support Vector Machine
% X = matrice delle feature ,
& Y = array delle etichette (labels)
svm_model = fitcsvm(X, Y, 'KernelFunction', 'linear',
'Standardize', true);

% Addestramento equivalente con k-NN
knn_model = fitcknn(X, Y, 'NumNeighbors', 5,
'Standardize', true);

% Validazione tramite K-Fold (es. K=5) al posto
% del semplice Holdout
cv_model = crossval(svm_model, 'KFold', 5);

% Stima dell'errore generale (media sui K fold)
cv_loss = kfoldLoss(cv_model);
fprintf('Accuratezza - stimata - K-Fold: -%.2f%%\n',
(1-cv_loss)*100);

% Valutazione visiva delle performance
% con Matrice di Confusione
Y_pred = kfoldPredict(cv_model);
figure;
confusionchart(Y, Y_pred);
title('Matrice di Confusione - (Cross-Validation)');
```

Capitolo 7

Eserciziario per lo Scritto

Questo capitolo contiene esercizi risolti passo-passo simili a quelli proposti nelle esercitazioni e all'esame scritto.

7.1 Esercizio Tipo 1: Campionamento e Aliasing

Testo: Dato il segnale $x(t) = \sin(2\pi \cdot 100t)$, calcolare la frequenza di Nyquist. Se il segnale viene campionato a $F_s = 150$ Hz, qual è la frequenza alias percepita?

Risoluzione:

1. Identificare la frequenza del segnale: Dalla formula $x(t) = \sin(2\pi ft)$, otteniamo $f_{max} = 100$ Hz.
2. Calcolare la frequenza di Nyquist: $F_{nyq} = 2 \cdot f_{max} = 2 \cdot 100 = 200$ Hz.
3. Calcolo dell'alias: Poiché $F_s = 150$ Hz $<$ 200 Hz, non rispettiamo il teorema di Nyquist e si verificherà aliasing. La frequenza alias percepita si ottiene calcolando la distanza della frequenza del segnale dal multiplo più vicino di F_s : $f_{alias} = |F_s - f_{max}| = |150 - 100| = 50$ Hz.

7.2 Esercizio Tipo 2: Quantizzazione, SNR e Bitrate

Testo: Si vuole quantizzare un segnale con dinamica in ingresso tra 0 V e 5 V utilizzando un ADC a 8 bit. Calcolare i livelli, lo step Δ , l'approssimazione

del rapporto segnale/rumore di quantizzazione (SNR) in dB, e il bitrate se campionato a $F_s = 200$ Hz. Cosa succede se si passa da 8 a 16 bit?

Risoluzione:

1. **Livelli (L):** $L = 2^b = 2^8 = 256$ livelli.
2. **Step Δ :** $\Delta = \frac{V_{max}-V_{min}}{L-1} = \frac{5-0}{255} \approx 0.0196$ V.
3. **SNR (SQNR):** $SQNR_{dB} \approx 6.02 \cdot b + 1.76 = 6.02 \cdot 8 + 1.76 = 49.92$ dB.
4. **Bitrate:** Il bitrate si definisce come $R = b \cdot F_s = 8 \cdot 200 = 1600$ bps (bit per secondo).
5. **Passaggio a 16 bit:** L'SNR diventa $6.02 \cdot 16 + 1.76 = 98.08$ dB, con una notevole diminuzione del rumore (incremento di qualità). Il bitrate raddoppia ($16 \cdot 200 = 3200$ bps).

7.3 Esercizio Tipo 3: Filtraggio 1D (Array)

Testo: Dato l'array $x = [2, 3, 2, 20, 3, 2, 1]$, applicare un filtro Mediano (finestra $W = 3$) e un filtro di Media Mobile (Media, $W = 3$, con zero padding o mantenendo i bordi inalterati). Spiegare le differenze.

Risoluzione:

Consideriamo i punti interni per semplicità. Valutiamo $i = 3$ (valore 20) che è chiaramente uno spike.

- **Filtro Mediano ($W = 3$):**

- Centrato sul 20 ($x[3], x[4], x[5]$): $\{2, 20, 3\} \rightarrow$ ordinato $\{2, 3, 20\} \rightarrow$ Mediano = 3.
- Centrato sul secondo 2 ($x[2], x[3], x[4]$): $\{3, 2, 20\} \rightarrow$ ordinato $\{2, 3, 20\} \rightarrow$ Mediano = 3.

Il valore y mediano scarta l'outlier "20" considerandolo un rumore impulsivo. $y \approx [2, 3, 3, 3, 2, 2, 1]$.

- **Filtro Media ($W = 3$):**

- Centrato sul 20: $\frac{2+20+3}{3} = \frac{25}{3} \approx 8.33$.
- Centrato sul secondo 2: $\frac{3+2+20}{3} = \frac{25}{3} \approx 8.33$.

Il picco si è schiacciato (~ 8.3 invece di 20), ma si è "spalmato" sui campioni vicini alterandoli nettamente.

7.4 Esercizio Tipo 4: Valutazione Modelli (Matrice di Confusione)

Testo: Dato il risultato di un modello di rilevamento Spam (o Malattia), con $TP = 40, TN = 950, FP = 10, FN = 5$. Calcolare Accuracy, Precision, Recall e F1-Score. Spiegare quando l'Accuracy è ingannevole.

Risoluzione:

- **Accuracy:** $\frac{TP+TN}{TP+TN+FP+FN} = \frac{40+950}{1005} = \frac{990}{1005} = 0.985$ (98.5%).
- **Precision:** $\frac{TP}{TP+FP} = \frac{40}{40+10} = \frac{40}{50} = 0.80$ (80%).
- **Recall (Sensitivity):** $\frac{TP}{TP+FN} = \frac{40}{40+5} = \frac{40}{45} \approx 0.888$ (88.8%).
- **F1-Score:** $2 \cdot \frac{Precision \cdot Recall}{Precision + Recall} \approx 2 \cdot \frac{0.8 \cdot 0.888}{0.8 + 0.888} \approx 0.84$.

Analisi: L'Accuracy è molto alta (98.5%) e ingannevole. Questo perché il dataset è estremamente sbilanciato (Class Imbalance): i veri negativi (TN) dominano. Se un classificatore dicesse sempre "Non Spam", avrebbe un accuracy di $\frac{960}{1005} = 95.5\%$, pur non avendo capacità predittiva. In questi casi, F1-Score e Recall sono metriche più significative.

7.5 Esercizio Tipo 5: Energia e Potenza di una Sinusoide

Testo: Un segnale $x(t) = 10 \cos(2\pi ft)$ viene osservato su un singolo periodo T . Qual è l'energia E contenuta in quel periodo? Se la frequenza raddoppia, cosa succede alla potenza media su tempo infinito?

Risoluzione:

1. L'energia su un singolo periodo per una sinusoide di ampiezza A è data dall'integrale del quadrato, che equivale a $E_{periodo} = \frac{A^2}{2} \cdot T$. Sostituendo $A = 10$, otteniamo $E = \frac{100}{2}T = 50T$.
2. La potenza media teorica di una sinusoide su tempo infinito dipende *solo* dall'ampiezza ed è $P = \frac{A^2}{2}$. Essendo indipendente da f , se la frequenza raddoppia, **la potenza rimane invariata**.

7.6 Esercizio Tipo 6: Filtraggio di Segnali Fisiologici

Testo: Stai analizzando un segnale EDA/GSR. Il soggetto tocca accidentalmente l'elettrodo per un millisecondo, creando un picco stretto e altissimo (artefatto impulsivo). Vuoi estrarre la linea di base (SCL) senza distorcerla. Hai a disposizione un filtro di media mobile e un filtro mediano. Qual è la strategia/sequenza corretta?

Risoluzione: La sequenza corretta è: **Prima Filtro Mediano, poi Filtro di Media (o estrazione del trend)**. *Motivazione:* L'artefatto impulsivo (outlier) verrebbe "spalmato" da un filtro di media, inquinando temporalmente il segnale SCL. Applicando prima un filtro non-lineare (Mediano), il picco anomalo viene scartato completamente. A quel punto, sul segnale pulito, si può applicare un filtro passa-basso (media) per estrarre la linea di base.

7.7 Esercizio Tipo 7: Domande Teoriche di Machine Learning

Domanda 1: In un classificatore Random Forest, perché le performance sono solitamente migliori di un singolo Decision Tree?

Risposta: Perché essendo un algoritmo *Ensemble*, combina molti alberi diversi addestrati su sottoinsiemi randomici di dati e feature. Questo approccio basato sul voto a maggioranza **riduce la varianza** complessiva del modello e previene l'Overfitting tipico dei singoli alberi decisionali, che tendono ad imparare il rumore.

Domanda 2: Hai un dataset a forma di cerchio: i punti della classe A sono al centro, i punti della classe B formano un anello esterno. Come procedi con una SVM?

Risposta: Un iperpiano lineare non può separare le classi. Devo usare un **Kernel RBF (Gaussiano)** o Polinomiale. Il kernel proietta (trasforma) i dati in un nuovo spazio matematico a più dimensioni, rendendo le due distribuzioni linearmente separabili in quella nuova dimensionalità.

Domanda 3: Cosa indica il fenomeno dell'Overfitting in termini di Bias e Varianza?

Risposta: L'Overfitting si manifesta con **Basso Bias e Alta Varianza**. Il modello è talmente complesso che cattura perfettamente i dati di training (incluso il loro rumore casuale), ma diventa ipersensibile alle fluttuazioni, fallendo sui nuovi dati di test.

7.8 Esercizi Tipo 8: Campionamento e Quantizzazione (Multiple Choice & Calcoli)

7.8.1 Esercizi Numerici a risposta aperta

Esercizio 1

Un sensore cattura un segnale analogico la cui componente di frequenza più alta è 12 kHz. Il segnale deve essere digitalizzato garantendo un Rapporto Segnale-Rumore (SNR) di almeno 40 dB.

a. Qual è la frequenza di campionamento minima?

Per il Teorema di Nyquist, per non perdere informazioni:

$$f_s \geq 2 \cdot f_{max} \implies f_s = 2 \cdot 12 \text{ kHz} = \mathbf{24 \text{ kHz}}$$

b. Quanti bit di quantizzazione servono? (Usa la formula empirica dB)

La formula empirica per l'errore di quantizzazione (SQNR) è:

$$SNR_{dB} \approx 6.02 \cdot n + 1.76$$

Sostituendo 40 dB:

$$40 = 6.02 \cdot n + 1.76 \implies 6.02 \cdot n = 38.24 \implies n = \frac{38.24}{6.02} \approx 6.35$$

Poiché i bit devono essere interi, arrotondiamo per eccesso per garantire *almeno* 40 dB: **7 bit**.

c. Qual è il bitrate risultante?

Il bitrate R (bit per secondo) si calcola moltiplicando i campioni al secondo per i bit per campione:

$$R = f_s \cdot n = 24.000 \text{ Hz} \cdot 7 \text{ bit} = 168.000 \text{ bps} = \mathbf{168 \text{ kbps}}$$

Esercizio 2

Considera un convertitore Analogico-Digitale (ADC) a 8 bit che lavora in un range di tensione da 0V a 5V.

a. Quanti sono i livelli di quantizzazione?

$$L = 2^n = 2^8 = \mathbf{256} \text{ livelli}$$

b. Qual è la risoluzione (o "passo di quantizzazione")?

La risoluzione Δ indica i Volt coperti da un singolo gradino. Per coprire esattamente gli estremi si divide per $L - 1$:

$$\Delta = \frac{V_{max} - V_{min}}{L - 1} = \frac{5 - 0}{255} \approx 0.0196 \text{ V} = \mathbf{19.6 \text{ mV}}$$

c. Se il segnale in ingresso è di 2.15V, quale sarà il valore intero (livello) associato?

Per calcolare il livello associato, è **fondamentale** calcolare la differenza tra il segnale in ingresso e la tensione minima di fondo scala (V_{min}), per poi dividere per il passo Δ . Questa formula generale garantisce il corretto funzionamento anche con segnali bipolari o con offset:

$$Livello = \text{round} \left(\frac{V_{in} - V_{min}}{\Delta} \right)$$

Nel nostro caso specifico ($V_{min} = 0V$):

$$Livello = \text{round} \left(\frac{2.15 - 0}{0.0196} \right) = \text{round}(109.69) = \mathbf{110}$$

Attenzione (Errore Comune): Usare la formula semplificata $\text{round}(V_{in}/\Delta)$ funziona **solo** se $V_{min} = 0V$.

Se ad esempio avessimo avuto un ADC con range da $-5V$ a $+5V$ ($\Delta = \frac{10}{255} \approx 0.0392V$) e lo stesso ingresso di 2.15V, il calcolo errato darebbe:

$$\text{round} \left(\frac{2.15}{0.0392} \right) = 55 \quad (\text{Sbagliato, manca fondoscala negativo!})$$

Il calcolo corretto applicando la formula generale è:

$$\text{round} \left(\frac{2.15 - (-5)}{0.0392} \right) = \text{round} \left(\frac{7.15}{0.0392} \right) = \mathbf{182} \quad (\text{Corretto!})$$

7.8.2 Esercizi a Risposta Multipla: Ragionamento

- 3) Qual è lo scopo principale della quantizzazione nel processo di conversione analogico digitale?

Risposta: D. Mappare un insieme infinito di valori di ampiezza in un insieme finito di livelli discreti. (*Mentre il campionamento discretizza il TEMPO, la quantizzazione discretizza l'AMPIEZZA*).

- 4) In un quantizzatore uniforme, se l'intervallo dinamico del segnale è di 10 V e abbiamo 1024 livelli, quanto vale approssimativamente l'ampiezza di ogni gradino?

Risposta: C (Circa 10 mV).

$\Delta = 10/1024 \approx 0.0097$ V, ovvero circa 10 mV.

- 5) Cosa succede al rapporto segnale-rumore di quantizzazione (SQNR) se aumentiamo il numero di bit di risoluzione?

Risposta: C. Aumenta, migliorando la fedeltà del segnale rispetto al rumore. (*Ricorda la formula: ogni bit in più aggiunge circa ~ 6 dB al rapporto segnale-rumore*).

- 6) Qual è il valore massimo dell'errore di quantizzazione in un quantizzatore uniforme con ampiezza del gradino Δ ?

Risposta: D ($\pm\Delta/2$). L'errore massimo si ha quando il valore analogico cade esattamente a metà tra due gradini.

- 7) Aumentare la risoluzione da 8 bit a 16 bit in un segnale audio cosa comporta principalmente?

Risposta: B. Una riduzione del rumore di quantizzazione. (*La massima frequenza registrabile dipende dalla frequenza di campionamento f_s , non dai bit!*)

- 8) Se un segnale ha una frequenza massima di 15 kHz e viene campionato a 20kHz, quale fenomeno si verifica?

Risposta: B (Aliasing).

Nyquist richiede $f_s > 2 \cdot 15 = 30$ kHz. Avendo campionato solo a 20 kHz, si ha aliasing (frequenze fantasma o fold-over).

- 9) Di quanti decibel migliora il rapporto segnale-rumore se aumentiamo la risoluzione di 2 bit?

Risposta: A (Circa 12 dB).

Ogni bit fornisce ≈ 6.02 dB. Due bit forniscono $2 \cdot 6.02 \approx 12$ dB.

- 10) Il 'dither' viene utilizzato per:

Risposta: C. Rompere la correlazione tra l'errore di quantizzazione e

il segnale originale. (Aggiungendo rumore bianco prima di quantizzare, l'errore non segue più le forme d'onda della musica, risultando molto meno fastidioso all'orecchio umano).

- **11) Il rumore di quantizzazione diminuisce se:**

Risposta: C. Si aumenta il numero di bit del quantizzatore.

- **12) Se raddoppiamo il numero di bit di un quantizzatore da 8 a 16 bit , cosa succede al numero di livelli?**

Risposta: D. Aumenta di 256 volte.

Dimostrazione: Livelli a 8 bit = $2^8 = 256$. Livelli a 16 bit = $2^{16} = 65536$. Il rapporto è $\frac{65536}{256} = 256$.

7.8.3 Esercizi Energia e Potenza su Sinusoidi

Questi tre concetti sono fondamentali e spesso motivo di tranelli all'esame:

Regole d'oro della Sinusoide $x(t) = A \cos(2\pi ft)$:

- **Tempo infinito:** L'Energia è sempre ∞ . La Potenza media è finita e vale $P = A^2/2$.
- **Singolo Periodo T :** L'Energia in un periodo è $E_T = \frac{A^2}{2} \cdot T$.
- **Frequenza:** La potenza media dipende SOLO dall'ampiezza. **Se f varia, la Potenza resta invariata.**

- **13) Dato un segnale sinusoidale $x(t) = A \cos(2\pi ft)$ definito da $-\infty$ a ∞ , come viene classificato in termini di energia e potenza?**

Risposta: C. Energia infinita e Potenza finita (è il classico "segnale di potenza").

- **14) Un segnale $x(t) = 10 \cos(2\pi ft)$ viene osservato solo per un singolo periodo T . Qual è l'energia E contenuta in quel periodo?**

Risposta: A (50 T).

Calcolo: $E = \int_0^T x(t)^2 dt = \frac{A^2}{2} \cdot T = \frac{100}{2} \cdot T = 50T$.

- **15) Dato il segnale $x(t) = A \cos(2\pi ft)$, se la frequenza f raddoppia, cosa succede alla potenza media?**

Risposta: C. Rimane invariata. La formula della potenza $P = A^2/2$ non ha la frequenza tra i suoi parametri!

Capitolo 8

Casi di Studio: Dataset DEAP

8.1 Introduzione a DEAP

Il dataset **DEAP** (Database for Emotion Analysis using Physiological Signals) è uno standard di fatto per l'Affective Computing basato su segnali fisiologici e video facciali. Creato per sviluppare sistemi di riconoscimento delle emozioni, ha introdotto concetti essenziali riguardo all'acquisizione multimodale.

Le caratteristiche principali del protocollo di induzione emotiva usato in DEAP:

- **Stimoli usati:** Video musicali da 1 minuto scelti per indurre emozioni uniformemente distribuite nel piano di Russell.
- **Segnali Acquisiti:**
 - Segnali fisiologici classici periferici: GSR, ECG, Respiro, Temperatura, EOG, EMG.
 - Segnali Cerebrali: **EEG a 32 canali**.
 - Segnali Visivi: **Face Video** dei partecipanti.

8.2 Formato di Valutazione (Self-Assessment)

Subito dopo ogni video, il soggetto valutava il proprio stato emotivo usando il sistema visivo dei manichini **SAM (Self-Assessment Manikins)**, esprimendosi sulle seguenti dimensioni (su scala continua 1-9):

- **Arousal (Attivazione):** da Calmo a Eccitato.

- **Valence (Valenza):** da Triste/Negativo a Felice/Positivo.
- **Dominance (Controllo):** da Sottomesso a Dominante.
- **Liking (Gradimento):** quanto al soggetto è piaciuto il video.

8.3 Modality Fusion

Una delle conclusioni più importanti emerse dallo studio sul paper DEAP riguarda la **Modality Fusion** (fusione multimodale). Unendo **feature estratte dall'EEG** assieme a **feature estratte dai segnali periferici e dalla MCA (Multimedia Content Analysis degli stimoli video)**, le prestazioni dei classificatori sono notevolmente superiori rispetto all'uso di un singolo biosegnale.